第03堂｜巨量數據調度工程與非結構化資料轉換

學習目標

完成本堂課後，學員將能夠：

- 說明 AI Agent 處理大量資料的典型架構與流程
- 區別「結構化資料」與「非結構化資料」的差異
- 使用程式對試算表（Excel / CSV）進行讀取、篩選、排序與寫入
- 建立批次處理流程，自動化彙整來自多份活頁簿的異質資料

核心概念說明

1. 為什麼資料處理是 Agent 的核心能力？

在企業環境中，大量的工作時間花費在「整理資料」上：

- 把多份 Excel 報表合併成一份
- 從上百筆記錄中找出符合條件的資料
- 將不同格式的資料統一成標準格式

這些工作**重複性高、規則性強**，是 AI Agent 最能發揮價值的場景。

一個典型的企業痛點：

> 每個月月底，業務助理要花一整天，手動把 20 個業務員各自回傳的 Excel 報價單，複製貼上到一份匯總表裡，然後再計算每個業務的總業績。

如果用 Agent 處理，整個流程可以在幾分鐘內完成。

---

2. 結構化資料 vs. 非結構化資料

	結構化資料	**非結構化資料**
定義	有固定格式，可直接用程式讀取	沒有固定格式，需要解析才能使用
範例	Excel 表格、CSV 檔、資料庫	PDF 報告、電子郵件、掃描圖片
處理難度	相對容易	需借助 AI 或 OCR 技術
典型工作	篩選、排序、計算	資訊提取、摘要、分類

從非結構化轉為結構化的典型流程：

```
原始資料（PDF 合約、郵件內文、掃描文件）
    │
    ▼ AI / OCR 解析
提取關鍵欄位（廠商名稱、金額、日期）
```

```
      │
      ▼ 資料清理與驗證
結構化資料表（可存入 Excel 或資料庫）
      │
      ▼ 後續分析與報表生成
最終報告
```

---

3. Excel / CSV 自動化處理

在 Python 中，處理試算表最常用的工具是：

工具	適用情境	特點
openpyxl	讀寫 `.xlsx` 格式的 Excel	可保留原有格式、樣式
pandas	大量資料的分析與計算	功能強大，適合數據分析
csv 模組	讀寫 `.csv` 純文字表格	輕量，適合簡單場景

試算表操作的基本動作：

動作	說明
讀取（Read）	從檔案載入資料到程式
篩選（Filter）	只取出符合條件的列
排序（Sort）	依照某欄位大小排列順序
計算（Calculate）	加總、平均、計數等
寫入（Write）	把處理結果存回檔案

---

4. 跨活頁簿資料整合（批次處理）

批次處理（Batch Processing）是指一次性處理大量同類型任務，而不是一筆一筆手動處理。

跨活頁簿整合的典型場景：

```
資料夾結構：
  /業務報表/
    ├── 北區業務_王大明.xlsx
    ├── 中區業務_李小華.xlsx
    ├── 南區業務_張美玲.xlsx
    └── ... (共 20 個檔案)

目標：
  自動讀取所有檔案 → 彙整到一份 匯總表.xlsx → 計算各業務業績合計
```

批次處理的核心邏輯：

```
步驟1：找到所有需要處理的檔案
列出資料夾內所有 .xlsx 檔案 → 得到一個檔案清單

步驟2：逐一處理每份檔案（迴圈）
對 每個檔案 在 檔案清單 中:
    讀取該檔案的資料
    提取需要的欄位
    將資料加入「總彙整清單」

步驟3：整理與計算
對 總彙整清單 進行排序、計算、格式化

步驟4：輸出結果
將整理後的資料寫入新的 Excel 檔案
```

---

5. AI 在資料處理中的角色

傳統的資料處理需要明確的規則（「如果欄位 A 等於 X，就...」）。但現實世界的資料往**格式不統一**，這時 AI 就能發揮作用：

AI 的三個關鍵角色：

角色	說明	範例
格式識別	理解不同格式的資料代表什麼	「NT$12,000」「12000元」都代表 12000 元
缺失值補充	根據上下文推斷缺失的資訊	從「台北辦公室」推斷地區為「北區」
異常偵測	找出資料中不合理的值	業績填寫為負數 → 可能是錯誤

實作步驟（逐步教學）

實作一：讀取並篩選 Excel 資料

步驟 1：安裝必要套件

```
安裝 openpyxl 套件:
    pip install openpyxl

安裝 pandas 套件:
    pip install pandas openpyxl
```

步驟 2：準備測試資料

建立一個 `sample_data.xlsx`，包含以下欄位：

業務員	地區	銷售金額	日期

業務員	地區	銷售金額	日期
王大明	北區	50000	2025/07
李小華	中區	32000	2025/07
張美玲	南區	68000	2025/07
…	…	…	…

步驟 3：向 GitHub Copilot 描述需求

```
請幫我用 Python 和 pandas 寫一個程式：
1. 讀取 sample_data.xlsx 的資料
2. 篩選出「銷售金額」超過 40000 的記錄
3. 依照「銷售金額」由高到低排序
4. 計算所有業務員的銷售金額總計
5. 把結果輸出到新的 filtered_result.xlsx 檔案
```

實作二：批次彙整多份活頁簿

步驟 1：準備多份測試 Excel 檔案

在 `報表資料/` 資料夾中建立多個 xlsx 檔案（可手動建立 3-5 個模擬檔案）。

步驟 2：向 GitHub Copilot 描述需求

```
請幫我用 Python 寫一個批次處理程式：
1. 掃描「報表資料」資料夾內所有的 .xlsx 檔案
2. 讀取每個檔案的資料（假設欄位格式相同）
3. 把所有資料合併到一個 DataFrame
4. 新增一個「來源檔案」欄位，記錄每筆資料來自哪個檔案
5. 依照業務員計算各自的銷售金額加總
6. 將匯總結果輸出到「月份彙整報表.xlsx」
```

步驟 3：加入 AI 輔助的格式識別

在程式中加入 LLM 呼叫，讓 AI 幫助你處理格式不一致的問題：

- 有些欄位名稱不同（「業務」vs「業務員」）
- 有些金額格式不同（「$50,000」vs「50000」）

實作三：AI Agent 驅動的資料清理

步驟 1：描述整體 Agent 流程

```
我要建立一個資料清理 Agent：
1. 讀取一份包含格式不一致資料的 Excel 檔
2. 對每一列資料，呼叫 LLM API 進行格式標準化
3. 將清理後的資料寫回新的 Excel 檔案
4. 如果某一列資料 AI 無法確定，標記為「需人工審查」
請幫我設計這個程式的架構
```

程式碼範例（虛擬碼）

讀取與篩選試算表

```
載入 pandas 套件

# 讀取 Excel 檔案
資料表 = 讀取Excel("sample_data.xlsx", 工作表="Sheet1")

# 查看資料基本資訊
顯示 資料表的前5行
顯示 資料表的欄位名稱
顯示 資料表的資料筆數

# 篩選：銷售金額超過 40000
篩選結果 = 資料表[ 資料表["銷售金額"] > 40000 ]

# 排序：由高到低
排序結果 = 篩選結果.依照("銷售金額", 由大到小=真)

# 計算加總
總計 = 篩選結果["銷售金額"].加總()
顯示 f"篩選後總計：{總計}"

# 輸出到新 Excel 檔案
排序結果.寫入Excel("filtered_result.xlsx", 不含索引=真)
顯示 "結果已儲存"
```

批次彙整多份活頁簿

```
載入 pandas, os, pathlib 套件

資料夾路徑 = "報表資料/"
所有資料 = []  # 用來收集所有檔案的資料

# 掃描資料夾內所有 xlsx 檔案
對 每個檔案 在 列出資料夾(資料夾路徑, 篩選="*.xlsx") 中:
    顯示 f"正在處理：{檔案名稱}..."

    # 讀取當前檔案
```

```
    當前資料 = 讀取Excel(檔案路徑)

    # 加入「來源檔案」欄位
    當前資料["來源檔案"] = 檔案名稱

    # 加入總清單
    所有資料.加入(當前資料)

# 合併所有資料
彙整資料 = 合併所有(所有資料)

# 依業務員計算加總
業績彙總 = 彙整資料.依照("業務員").計算加總("銷售金額")

# 輸出
業績彙總.寫入Excel("月份彙整報表.xlsx")
顯示 f"完成！共處理 {len(所有資料)} 個檔案"
```

AI 輔助的格式標準化

```
函式 標準化欄位(原始值, 欄位類型):
    提示詞 = f"""
    我有一筆資料："{原始值}"
    這是「{欄位類型}」欄位的值。
    請將它轉換為標準格式：
    - 如果是金額：只回傳數字（不含符號與逗號）
    - 如果是日期：轉換為 YYYY-MM-DD 格式
    - 如果無法判斷：只回傳「UNKNOWN」
    只回傳結果，不要說明。
    """
    回傳 呼叫LLM(提示詞)

# 對每一列資料進行標準化
對 每一列資料 在 資料表 中:
    資料["銷售金額"] = 標準化欄位(資料["銷售金額"], "金額")
    資料["日期"]   = 標準化欄位(資料["日期"], "日期")

    如果 任何欄位 == "UNKNOWN":
        資料["備註"] = "需人工審查"
```

練習題 / 作業

課堂練習

練習 1：設計資料處理流程

你的公司有以下情境，請設計一個 Agent 的處理流程（可用文字或流程圖）：

> 每週一，各部門主管會以電子郵件回傳一份本週銷售紀錄的 Excel 檔案（格式略有不同）。需要自動彙整所有部門的銷售資料，計算各部門總業績，並生成一份比較報表。

請說明：

- 需要哪些步驟？
- 每個步驟的輸入和輸出是什麼？
- 哪些地方可能出現問題？

練習 2：資料識別

以下資料代表同樣的含義，但格式不同。請判斷 AI 需要做哪些處理才能統一它們：

原始資料	應標準化為
NT$12,500	
1萬2千5百元	
12500.00	
$12,500 USD	

課後作業

1. **動手實作**：在你的電腦上建立 3 份格式相同的 Excel 檔案（可手動填寫一些測試資料），然後用 GitHub Copilot 協助你寫一個批次彙整程式。
2. **格式挑戰**：將 3 份 Excel 故意使用不同的欄位名稱（如：「姓名」vs「業務員」vs「員工」），看看你的程式能否正確合併，或是需要額外的處理。

延伸閱讀

工具文件：

- pandas 官方文件 — https://pandas.pydata.org/docs/
- openpyxl 官方文件 — https://openpyxl.readthedocs.io/

資料處理概念：

- 《Python for Data Analysis》by Wes McKinney — pandas 作者撰寫的資料分析聖經
- ETL（Extract, Transform, Load）概念介紹 — 可搜尋「ETL pipeline 教學」

AI + 資料處理：

- LangChain CSV Agent 教學 — LangChain 官方文件的 CSV 處理章節